

國立中興大學資料科學與資訊計算研究所

碩士學位論文

基於 Cycle-GAN 與領域適應技術的

自動染色體分割系統:應用於跨院驗證

Automatic chromosome segmentation system

based on Cycle-GAN and domain adaptation

technology : Applied in Cross-Hospital

Validation

國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

指導教授：郭至恩 Chih-En Kuo

研究生：林宗佑 Tsung-Yu Lin

中華民國一百一十三年八月

國立中興大學 資料科學與資訊計算研究所

碩士學位論文

題目：基於 Cycle-GAN 與領域適應技術的自動染色體分割

系統：應用於跨院驗證

姓名：林宗佑 學號：7111095022

經 口 試 通 過 特 此 證 明

論文指導教授

郭至恩

論文考試委員

郭至恩

吳勝富

江振國

余靜璇

郭至恩

中華民國 113 年 6 月 18 日

誌謝

時光匆匆，碩士兩年的時間一眨眼就過去了，身為一個非本科生，最初接觸到人工智能、深度學習時，也曾擔心自己能不能跟上別人的腳步。很感謝家人及女友的支持，回想起當初毅然決然決定轉換跑道的決定，我也非常慶幸自己做了正確的決定。

首先我想感謝指導教授郭至恩教授，在碩一時提供一些與廠商合作的案子，讓我可以一步一腳印的去摸索，並有系統性地完成目標。在摸索的過程中加速了自己對編寫程式及深度學習的熟練度。此外還有在文章撰寫的提點上，讓我意識到自己在寫作上需要留心及不足之處。感謝實驗室學長姐仁傑及俐瑗，因為有你們在，實驗室總是充滿輕鬆與開朗的氛圍。感謝學弟宇凡跟雲明，每周總是有固定時段一起去運動，讓我在研究之餘不會感受到枯燥乏味。感謝研究所生涯中相處最久的浩翔、彥均、映璇，因為有你們的相互討論及砥礪，所以我才能不斷的在學業中進步，我很感激也很慶幸遇見了你們，真的。

謝謝我的家人及女友語桓，你們無條件的支持才能讓我無所懼的往前邁進，在挫折的時候，也是因為你們使我振作。特別感激我的女友語桓，我記得當初錄取研究所時，那不是喜極而泣的眼淚，而是滿滿捨不得。謝謝妳陪我這兩年，即使我身陷泥沼，妳還是會努力拉我上岸。這一路上要感謝的人不勝枚舉，如果沒有你們的幫助，我想我很難走到這一步，在這裡獻上我深深的感謝。

最後我想將此文獻給天上的外婆，想說的話太多太多，礙於篇幅，我就先放心裡，等到未來相遇時再慢慢說。就讀研究所期間經歷到的酸甜苦辣，都是人生中的寶貴經驗，我會帶著這些回憶，往人生下一階段努力。

學生 林宗佑 謹誌於

中興大學 理學院 資料科學與資訊計算研究所

中華民國 113 年 6 月

摘要

領域適應旨在使特定領域(源域)訓練完成的深度學習模型可以有效地應用在另一個不同但有相關性的領域(目標域)上，不必再透過目標域的數據及標籤重新訓練模型。這節省了大量的標註人力及時間，進而大幅度提升深度學習模型在應用的實用性。

在單條染色體分割任務中，從不同來源收集的染色體影像會因為儀器參數設定、型號不同或是不同醫院醫檢師操作流程不一樣而導致染色體影像有明顯的差異，這些差異往往會影響深度學習演算法的準確度。故本篇論文將提出一個基於領域適應的染色體分割方法，期望能有效降低標註成本且有效分割不同來源下的染色體。

本研究使用台中榮民總醫院的染色體圖像，8000 個單條染色體物件，以及台北長庚紀念醫院的染色體圖像，8000 個單條染色體物件來進行模型訓練，使用 MIoU 及 Dice coefficient 做為評估分割模型效能的指標。整體架構可分為兩個階段，在第一階段，我們將使用榮總醫院及長庚醫院的染色體訓練風格轉換模型 CycleGAN，並使用其風格轉換生成器將兩個醫院的染色體進行風格轉換。第二階段，我們提出三種不同的領域適應策略，這些策略分別使用了長庚轉榮總及榮總轉長庚的風格轉換模型。第一種策略使用 U-net 及師生模型架構進行領域適應，首先可以透過台中榮總的染色體物件及其標籤訓練一個可良好分割台中榮總染色體的模型，並將該模型權重用於初始化教師模型以及學生模型。再來將長庚染色體圖片輸入至學生模型;將經過風格轉換後的長庚染色體圖片輸入至教師模型，並利用教師模型的輸出機率計算熵做為每個像素的損失權重。最後使用兩個模型的結果計算損失函數後更新學生模型，然後使用更新後的學生模型權重更新教師模型，藉此使模型在長庚染色體的分割上達到更好的效果。第二種策略使用 U-net 結合自適應實例歸一化(AdaIN)使得不同醫院間染色體圖片特徵的統計量相近，藉此達成領域適應的目的。第三種策略我們將自適應實例歸一化及師生模型架構兩種方法結合，在評估指標上得到最好的結果。在實驗結果上三種策略所訓練的模型效能皆優於未經領域適應模型的效能。同時我們也使用了其他不同領域適應的方法

進行比較，而在評估指標上的表現也證實了我們的方法在染色體資料庫是優於其他領域適應方法，期待此方法能有效降低標記人力及時間成本，幫助醫檢師快速分割染色體。

關鍵詞：深度學習、語意分割、領域適應、風格轉換



國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

Abstract

Domain adaptation aims to enable a deep learning model trained in a specific domain (source domain) to be effectively applied in another different but related domain (target domain) without the need to retrain the model using the target domain's data and labels. This saves a significant amount of annotation labor and time, greatly enhancing the practicality of deep learning models in applications.

In the task of single chromosome segmentation, chromosome images collected from different sources often exhibit noticeable differences due to variations in instrument parameter settings, difference of instruments, or different operational procedures of medical technologists at different hospitals. These differences can often affect the accuracy of deep learning algorithms. Therefore, this paper proposes a chromosome segmentation method based on domain adaptation, aiming to effectively reduce annotation costs and efficiently segment chromosomes from different sources.

This study uses chromosome images from Taichung Veterans General Hospital, with 8000 single chromosome objects, and chromosome images from Taipei Chang Gung Memorial Hospital, also with 8000 single chromosome objects for model training. The performance of the segmentation model is evaluated using the Mean Intersection over Union (MIoU) and Dice coefficient. The overall framework can be divided into two stages. In the first stage, we use chromosome images from both Taichung Veterans General Hospital and Chang Gung Memorial Hospital to train a style transfer model, Cycle-GAN, and use its style transfer generator to perform style transfer on the chromosomes from the two hospitals. In the second stage, we propose three different domain adaptation strategies, using style transfer models from Chang Gung to Veterans General and from Veterans General to Chang Gung. The first strategy employs the U-net and Teacher-Student framework for domain adaptation. Initially, a model that can well segment chromosomes from Taichung Veterans General is trained using its chromosome objects and labels, and the model weights are used to initialize both the teacher model and the student model. Next, the Chang Gung chromosome images are input into the student model; the style-transferred Chang Gung chromosome images are input into the teacher model, and the entropy of the teacher model's output probabilities is used as the loss weight for each pixel. Finally, the student model is updated by calculating the loss function from the

results of the two models, and then the updated student model weights are used to update the teacher model, thereby achieving better segmentation results on Chang Gung chromosomes. The second strategy uses U-net combined with Adaptive Instance Normalization (AdaIN) to make the statistical features of chromosome images from different hospitals similar, thereby achieving domain adaptation. The third strategy combines the Adaptive Instance Normalization and Teacher-Student framework, obtaining the best results in the evaluation metrics. The experimental results show that the performance of the models trained with the three strategies all surpassed the performance of models without domain adaptation. We also compared our methods with other domain adaptation methods, and the evaluation metrics confirmed that our methods outperformed other domain adaptation methods on the chromosome database. We expect that this method can effectively reduce the labor and time cost of annotation, helping medical technologists quickly segment chromosomes.

Keywords: Deep Learning, Semantic Segmentation, Domain Adaptation, Style Transfer

國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

目錄

摘要	i
Abstract.....	iii
目錄	v
圖目錄	vii
表目錄	ix
第一章 緒論	1
1.1 研究動機	1
1.2 文獻探討	2
1.3 研究目的	3
1.4 文章架構	3
第二章 資料來源與研究方法	5
2.1 資料來源	5
2.2 相關文獻方法介紹	7
2.2.1 風格轉換方法介紹	7
2.2.2 U-net	10
2.2.3 損失函數介紹	11
2.3 資料處理	13
2.4 基於領域適應染色體分割演算法	14
2.4.1 基於師生模型下的領域適應方法	14
2.4.2 基於風格校正下的領域適應方法	16
2.4.3 結合風格校正與師生模型的領域適應方法	18

2.5 性能評估指標	20
第三章 實驗結果	22
3.1 訓練超參數設定與實驗設置	22
3.2 Cycle-GAN 風格轉換結果呈現	24
3.3 領域適應技術對語意分割模型效能評估	28
第四章 討論	34
4.1 參數設定對師生模型效能評估	34
4.2 複合損失函數對分割模型效能評估	36
4.3 文獻方法比較	39
4.4 應用於語意分割模型的決策可視化	42
第五章 結論與未來方向	45
5.1 結論	45
5.2 未來方向	45
參考文獻	48

國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

圖目錄

圖 2.1 台中榮總染色體影像(左)與林口長庚染色體影像(右).....	5
圖 2.2 Image Labeler 軟體標記介面	7
圖 2.3 cycle GAN 示意圖	8
圖 2.4 AdaIN 架構圖	9
圖 2.5 U-net 架構圖	10
圖 2.6 資料處理流程圖	13
圖 2.7 本論文提出之領域適應方法流程圖	14
圖 2.8 ADVENT 中未使用領域適應對源域及目標域圖片分割結果	15
圖 2.9 基於師生模型下的領域適應方法	16
圖 2.10 基於風格校正下的領域適應方法架構圖	18
圖 2.11 結合風格校正與師生模型領域適應方法第一階段訓練示意圖	19
圖 2.12 結合風格校正與師生模型領域適應方法第二階段訓練示意圖	19
圖 2.13 交並比示意圖	21
圖 3.1 Resnet-152 於 Stage 1 (a)、Stage 2 (b)、Stage 3 (c)、Stage 4 (d)特徵圖 取格 拉姆矩陣對角元素後 t-SNE 圖	25
圖 3.2 Resnet-152 於 Stage 1 (a)、Stage 2 (b)、Stage 3 (c)、Stage 4 (d)特徵圖	26
圖 3.3 原始圖片及 Cycle-GAN 風格轉換圖片	27
圖 3.4 (a)目標域染色體圖、(b)染色體物件、(c)Teacher-Student 領域適應模型分割 結果	31
圖 3.5 (a)目標域染色體圖、(b)染色體物件、(c)AdaIN 領域適應模型分割結果	32
圖 3.6 (a)目標域染色體圖、(b)染色體物件、(c)AdaIN 結合 Teacher-Student 領域適 應模型分割結果	33
圖 4.1 不同參數設定下對教師模型 MIoU 表現.....	35

圖 4.2 不同參數設定下對教師模型 Dice coefficient 表現.....	35
圖 4.3 目標染色體及背景像素 pixel embedding t-SNE 圖.....	38
圖 4.4 (a) 源域圖片、(b)目標域圖片、(c) 使用 ClassMix 生成圖片	41
圖 4.5 未重疊染色體 Grad-CAM 圖	43
圖 4.6 重疊染色體 Grad-CAM 圖	44
圖 5.1 未來研究方向示意圖	47



國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

表目錄

表 2.1 訓練集及測試集詳細資料	6
表 2.2 混淆矩陣分類定義	21
表 3.1 訓練超參數設定	23
表 3.2 Asymmetric Loss 參數設定	23
表 3.3 合成圖片經二元分類器分類之準確度	24
表 3.4 目標域 457 張染色體物件評估結果	28
表 3.5 目標域 1523 張染色體物件評估結果	30
表 4.1 不同損失函數組合對模型效能評估	36
表 4.2 方法與文獻比較	39
表 4.3 DAFormer 消融性實驗結果	41

國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

第一章 緒論

1.1 研究動機

染色體為細胞內具有遺傳性質的物質所形成之聚合體，是遺傳學的主要研究項目。異常的染色體數量或結構會導致染色體相關疾病，近年來由於人們對染色體異常疾病的理解增加，許多孕婦在孕期間會接受產前檢測以得知胎兒是否患有染色體相關疾病的風險。然而，使用人工方式分析染色體其效率較低，隨著健康意識提升，產前檢查也日益普及。且隨著邁向高齡化社會，台灣醫療資源可以觀察到飽和的趨勢，甚至已經不堪負荷，這也說明了電腦輔助在醫療上重要性的比重逐年上升。近年來，由於電腦計算能力的增加，深度學習廣泛且成功應用在醫學影像處理上。

但機器學習/深度學習技術在電腦視覺應用上時常因為訓練及測試樣本數據分佈不一致而導致其準確率低下，而同樣的問題也體現在基於深度學習染色體分割技術。近年來，深度學習在電腦視覺領域上大放異彩，這無疑是因為深度學習算法的大參數模型可以良好的適配在數據上，但伴隨而來的是深度學習通常需要大量的人工標記。而在醫療影像語意分割任務中所使用的像素分割標記更是需要花費標記人員大量的時間與精力，而且染色體的邊緣是很難勾勒的，這需要多個標記人員反覆確認染色體邊緣的像素標記是否正確，因此標記一張染色體圖像需要花費標記人員大量的時間及精力。但這是一個即使需要大量人力、時間成本卻不能省略的步驟。而在收集資料的過程，使用不同型號的儀器或參數，會使得數據的品質有些許的差異，而這些差異也會影響深度學習的準確率，以致於無法直接將使用源域(source domain)訓練的模型應用於目標域(target domain)的資料上。當已經擁有某間醫院的染色體影像及其標籤，如何利用已有的資料、標籤對去訓練一個模型可以良好的適配在目標域，進而節省額外耗費人力及時間的目標域人工標記，是一個迫切需要解決的問題。

1.2 文獻探討

醫療影像分割在醫療領域有著許多需求，例如細胞分割、腫瘤分割、視網膜血管分割以及染色體分割。而取得醫療影像的過程中，由於不同的儀器、不同的掃描協定(scanning protocols)及不同醫院間樣本統計差異，不同來源的醫療影像往往具有不同的分布特性，這種分布差異導致醫療影像分割任務在不同來源的影像上表現會有落差。本節首先將回顧關於醫療影像分割的方法，再回顧一些應用於醫療影像上的領域適應研究。

早期的醫療影像分割方法主要依賴邊緣檢測、樣板比對及機器學習方法，Yu-qian 等人[1]提出了一種結合了型態學運算的邊緣檢測演算法。而 Chen 等人[2]利用樣板比對在腦部電腦斷層圖片上進行醫療影像分割，Li 等人[3]使用了水平集(level set)和支援向量機(SVM)來進行醫療影像分割。雖然有許多方法在特定的醫療影像分割上取得了成功，但醫療影像分割仍然面臨到挑戰，因為醫療影像相較於一般圖片通常具有較多雜訊跟具有低對比度的情況，而這些圖片品質的缺陷讓研究者很難透過人為定義的方式得到具有鑑別性的特徵。由於深度學習技術的快速發展，研究者不必再透過人為定義影像特徵，而是可直接透過神經網路自身去學習影像特徵。在醫療影像分割任務中，U-net [4]這一深度學習模型被廣泛應用，U-net 透過其全卷積的結構，讓模型的輸出變成空間維度的輸出而不再是單一標籤。並透過跳躍式連接將編碼器及解碼器相同尺度上的特徵做連接，進而達到良好的影像分割效果。

接著回顧有關醫療影像分割結合領域適應的相關文獻，Gadermayr 等人[5]利用 Cycle-GAN 進行圖像對圖像的轉換，並利用轉換後的圖像訓練 U-net 並將其使用在腎臟切片的分割任務上。Chen 等人[6]則是同時在影像及特徵上進行領域差異校正，透過將源域圖片轉換為目標域風格圖片，並分別將真實目標域圖片及目標域風格圖片輸入至具有兩個分支的卷積網路中，然後透過鑑別器進行對抗式學習以減少領域間差異。Yang 等人[7]則是透過解耦表征來進行領域適應並應用在肝臟分割任務中。Perone 等人[8]使用了自集成架構下的訓練方式，該架構包含了一個學生網路及教師網路。透過將源域資料及標籤訓練學生網路，並將目標域資料提供給教師網路，藉由最小化教師網路及學生網路輸出的差異藉此減少領域差異性。

在醫療影像的領域適應技術回顧中，許多方法皆使用到 Cycle-GAN 進行影像差異校正來達到領域適應的目的，但這些方法大多只針對影像差異進行校正，對於影像細節特徵並沒有進行差異校正。雖然 Chen 等人所提出了方法透過結合 Cycle-GAN 以及對抗式學習來達到在影像及特徵上進行領域差異校正，但對抗式學習架構下的訓練過程通常比較不穩定，常由於生成器及鑑別器其中一方過於強大導致模式崩潰。

1.3 研究目的

目前基於深度學習下的染色體分割方法，通常需要大量的資料來訓練模型。但收集染色體影像的過程中，可能因為影像資料來源不一致，像是使用不同型號的儀器或不同參數設定來獲得染色體影像，前述原因會導致不同來源染色體影像存在差異性。像是對比度的差異或是影像像素分佈差異，這使得基於深度學習下的染色體分割方法會因為訓練資料及測試資料的分佈不一致而導致方法效能降低，這種現象也被稱為領域適應問題。

領域適應問題指的是訓練模型時，模型通常在某個特定的來源域(source domain)上進行訓練，但在應用時需要處理不同的目標域(target domain)。在來源域和目標域的數據分佈差異的情況下，直接將源域訓練得到的模型應用到目標域可能導致性能大幅下降，這是因為模型無法適應目標域的特徵。領域適應技術的目標是不需要額外大量來自目標域的標記數據成本重新訓練模型，而是通過某種方式使模型能夠在目標域上具有泛化能力，在臨床應用上，染色體影像來源可能源自多家醫院。如果缺乏了領域適應技術，臨床表現上會因為資料分佈不一致導致效能降低，故本研究旨在開發出一款基於領域適應技術的染色體分割系統。

1.4 文章架構

本論文一共分為五個章節，內容依序如下:第一章為緒論，主要用於說明本論文之研究動機、文獻探討、研究目的。第二章介紹使用的資料集及資料來源、相關工作、資料處理流程、領域適應方法及效能評估指標。第三章為實驗超參數及實驗設置、風格轉換結果呈現及分割效能評估，第四章為討論，包含領域適應技

術中參數對分割效能影響、文獻結果比較及決策熱圖可視化，最後第五章為本論文之結論及未來方向。



國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

第二章 資料來源與研究方法

2.1 資料來源

本論文使用之資料集分別來自台中榮民總醫院以及林口長庚醫院，圖 2.1 為台中榮總的染色體影像(左)與林口長庚的染色體影像(右)，染色體物件數量分別為 8000 及 9523。源域(source domain)為台中榮總的染色體物件，且 8000 張影像皆有對應之像素標記;目標域(target domain)為林口長庚的染色體物件，且長庚醫院染色體數據集又切分成訓練集 8000 個染色體物件及測試集 1523 個染色體物件。只有測試集有對應之像素標記，且榮總訓練集、長庚訓練集及長庚測試集中皆含有 22 對體染色體物件及性染色體物件。訓練集中每對染色體物件數量皆在 340 至 350 之間不等，測試集中每對染色體物件數量皆在 60 至 70 之間不等，確保模型皆在使用每對染色體進行訓練及評估，資料集資訊如表 2.1 所示。




圖 2.1 台中榮總染色體影像(左)與林口長庚染色體影像(右)

表 2.1 訓練集及測試集詳細資料

Source	Chromosome instances dataset	Instances	Pixel Label
Chang Gung Memorial Hospital (Target domain)	Training Set	8000	✗
	Testing Set	1523	✓
Taichung Veterans General Hospital (Source Domain)	Training Set	8000	✓

本論文使用的單條染色體圖像會透過物件偵測模型[9]對核型圖進行偵測，再透過 python 程式將偵測到的物件框擷取出來。染色體圖像像素標記則使用了 Matlab 中的 Image Labeler 軟體對台中榮總醫院所有染色體及台北長庚醫院測試集中的染色體進行像素標記，在標記過程中會根據染色體的特徵進行像素標記，並透過第二位標記人員進行標記檢查檢查像素標記的正確性，標記完成後再透過 python 程式將標記影像像素值從 0/1 轉換成 0/255。我們統計了標記過程中所需的時間及對應的張數，平均每小時標記 15 至 20 張染色體不等，這也再次反映了像素標記所需要的大量人力、時間成本，圖 2.2 為 Matlab 中 Image Labeler 的標記介面圖。

在模型訓練階段，我們使用了榮總染色體訓練集及對應之像素標籤以及無像素標籤的長庚染色體訓練集進行訓練，且並未將 23 對染色體物件進行類別分類後再進行訓練，而是將所有不同類別染色體混合進行訓練。這是由於單條染色體影像必須透過物件偵測模型產出，而當染色體重疊過多導致染色體特徵被遮擋時，會導致物件偵測模型無法偵測到該條染色體最終導致收集之染色體物件數量不一致。一張正常染色體圖像應有 22 對體染色體及一對性染色體，而性染色體又依性別分為 X 染色體及 Y 染色體，其中 Y 染色體樣本數相較其他染色體較為稀少。為了保持模型穩定性，故將不同類別染色體混合進行訓練。




圖 2.2 Image Labeler 軟體標記介面

2.2 相關文獻方法介紹

本論文之基於領域適應染色體分割演算法主要分成兩個階段: (1) 使用榮總及長庚單條染色體影像訓練 Cycle-GAN 並產出兩個不同方向的風格轉換模型。(2) 結合第一階段產生的風格轉換模型，搭配三種不同領域適應策略來進行染色體分割。後面將詳細介紹演算法及模型細節。

为了更好的理解整個演算法的流程及細節，在本節我們會介紹使用到的相關文獻，包含了風格轉換方法 Cycle-GAN、AdaIN、影像分割模型 U-net 以及損失函數。

2.2.1 風格轉換方法介紹

2.2.1.1 Cycle GAN

Cycle GAN [10] 是由 Jun-Yan Zhu 等人在 2017 年提出，Cycle GAN 旨在實現兩個不同圖像域之間的風格轉換，訓練過程中無需成對的訓練數據。傳統的圖像風格轉換通常需要成對的圖像，即每個輸入圖像都必須有一個對應的輸出圖像，這導致了數據收集上的困難，限制了風格轉換方法的應用範圍。

而 Cycle GAN 透過引入兩個生成器和兩個鑑別器來解決這個問題，圖 2.3 為 cycle GAN 架構示意圖，其中 X 跟 Y 分別代表不同域(domain)的資料。具體來說，對於兩個不同的圖像域(如馬和斑馬的圖像)，Cycle GAN 包括一個將圖像從 X 域轉換到 Y 域的生成器(G)和一個將圖像從 Y 域轉換回 X 域的生成器(F)。同時，還有兩個鑑別器 D_X 及 D_Y ，分別用於評估 X 域和 Y 域的圖像是原本圖像還是經過風格轉換後的圖像。

用來訓練的損失函數主要有三個部分:(1)對抗式損失(adversarial loss)、(2)身份損失(Identity Loss)、(3)循環一致性損失(cycle consistency loss)。對抗式損失為生成器需要試著將轉換的圖片騙過鑑別器，使鑑別器將其誤以為真;而鑑別器則是需要正確的判斷圖片是經由生成器轉換過的假圖片或是真實圖片，而這種藉由生成器及鑑別器互相對抗下所產生出的損失函數便是對抗式損失。身份損失目的是確保生成器能夠保留輸入圖像的重要信息。身份損失主要希望當輸入圖片已經是該生成器轉換的風格時，仍需要保持輸入圖像原本的風格。最後是循環一致性損失，核心思想是希望原始圖片經過兩種不同風格轉換方向的生成器後所產生的圖片必須跟原始圖片保持一致。換句話說，如果將一個圖像從 X 域轉換為 Y 域，然後再轉換回 X 域，最終的圖像應該與原始圖像保持一致。這種循環一致性有助於使生成的圖像更加自然和逼真，這也是 Cycle GAN 的關鍵思想。




圖 2.3 cycle GAN 示意圖 [10]

2.2.1.2 AdaIN

AdaIN [11]全名為 "Adaptive Instance Normalization"，是一種用於圖像風格轉換的方法。透過給予一張參考圖像及輸入圖像，實現將輸入圖像的風格轉換為參考圖像的風格，且訓練也無需成對的訓練數據。

AdaIN 通過將輸入圖像的特徵組合與風格參考圖像的統計信息進行調整來實現風格轉換。具體來說，AdaIN 透過計算輸入圖像和風格參考圖像在經過編碼器輸出後的特徵圖各自的平均值和標準差，然後將輸入圖像的每個特徵頻道的平均值和標準差調整為風格參考圖像的對應統計量。這樣就可以將輸入圖像的風格轉換為風格參考圖像的風格。與傳統的風格轉換方法相比，AdaIN 具有一些優勢。首先，它不需要成對的訓練數據，因此更加靈活。其次，它可以在不同的風格參考圖像之間進行風格轉換，而不需要重新訓練模型。最後，AdaIN 的運算速度相對較快，這使得它在實時應用中更加可靠，圖 2.4 為 AdaIN 實現風格轉換的整體架構圖。




圖 2.4 AdaIN 架構圖[11]

2.2.2 U-net

U-net [4]是一種深度學習模型，專門用於生物醫學影像分割任務。而影像分割是指將一張影像中的每個像素分配給特定的類別，在醫學影像解析、診斷中是一個重要及常見的任務。

U-net 的網絡結構被設計成對稱的 U 形，因此得名，主要包括兩個主要部分：編碼器（Encoder）和解碼器（Decoder）。編碼器類似於常見的卷積神經網絡（CNN），用於提取影像的特徵。然而，U-net 使用了跳躍式連接（Skip Connections）將編碼器部分特徵圖與解碼器相對應尺度的特徵圖進行連接，以保留更多圖像的空間資訊，這樣的結構有助於解碼器還原原始圖像尺寸時處理細節和結構性特徵時的不足。解碼器中則使用了上採樣(upsampling)將編碼器提取的特徵資訊還原為原始影像的尺寸，最終生成與原始影像相同尺寸的分割結果。

U-net 在醫學影像分割任務中取得了極好的成果，並且被廣泛應用於生物醫學、醫學影像分析等領域。它的成功在於其獨特的網絡結構使得其能高效捕捉影像中的特徵資訊，從而在影像分割任務中取得了優異的性能，圖 2.5 為 U-net 模型架構圖。




圖 2.5 U-net 架構圖[4]

2.2.3 損失函數介紹

2.2.3.1 Cross Entropy

Cross Entropy 為深度學習分類任務中常用的指標之一，目的在衡量模型預測機率分佈以及真實標籤的機率分佈之間的差異。降低 Cross Entropy 可以使得模型預測分佈靠近真實標籤的機率分佈。

對於給定真實標籤 y 及模型預測機率分佈 p ，Cross Entropy 可定義為

$$H(y, p) = -\sum_i y_i \log(p_i) \quad (2.1)$$

2.2.3.2 Asymmetric Loss

Asymmetric Loss [12] 是基於 Focal Loss 進行改良的一種損失函數，主要被應用在多標籤分類任務上，Asymmetric Loss 主要由兩個部分貢獻，分別是正樣本貢獻的損失 L_+ 及負樣本貢獻的損失 L_- 。其計算公式如式(2.2)-(2.3)。

$$ASL = \begin{cases} L_+ = (1 - p)^{r_+} \log(p) \\ L_- = (p_m)^{r_-} \log(1 - p_m) \end{cases} \quad (2.2)$$

$$p_m = \max(p - m, 0) \quad (2.3)$$

r_+ 及 r_- 是可設定的超參數，用來控制正樣本及負樣本中樣本難易程度對損失貢獻的程度，越簡單的樣本其權重越低，越困難的樣本其權重越高。而(2.3)中的 m 為一可設定之閾值，目的在解決正負樣本不平衡的情況，透過平移模型預測之機率，可以降低簡單負樣本所貢獻的損失，藉而舒緩負樣本較多導致負樣本所貢獻的損失遠大於正樣本損失的情況。

2.2.3.3 Style Loss

本論文使用於衡量特徵圖風格差異的損失函數如(2.4)所示。其中 $g(\cdot)$ 為編碼器， $f(\cdot)$ 為解碼器， i 為 U-net 架構中編碼器及解碼器層數之索引， L 為編碼器及解

碼器中總層數。 s 為風格圖像， t 為目標圖像，而 $\mu(\cdot)$ 為取向量平均， $\sigma(\cdot)$ 為取向量標準差。

$$\begin{aligned} Style\ Loss = \sum_{i=1}^L \left\| \mu(g_i(s)) - \mu(f_{L-i}(g(t))) \right\|_2 + \\ \sum_{i=1}^L \left\| \sigma(g_i(s)) - \sigma(f_{L-i}(g(t))) \right\|_2 \quad (2.4) \end{aligned}$$

風格損失(Style Loss)的計算首先保留 U-net 編碼器的每一區塊(block)輸出”風格圖像”特徵圖的統計量(平均值及標準差);再計算”目標圖像”經由 U-net 編碼器壓縮後，輸入至解碼器每一區塊(block)的特徵圖統計量(平均值及標準差)，然後計算對應統計量的均方誤差(Mean Square Error)並加總得到最終的損失。

2.2.3.4 Variance Loss

本論文參考了文獻[13]中的損失函數的變異數損失(Variance term)，該函數目的是為了降低屬於同一類別像素在特徵空間的變異數。透過深度學習模型將圖片的每個像素映射到高維空間後，計算每個類別像素在高維空間的平均向量，並希望屬於同類別的像素與其平均向量在高維空間中越接近越好，而在本篇論文中要解決的問題屬於二分類問題，所以我們根據像素標籤，計算屬於目標染色體(像素標籤為 1)在高維空間的平均向量，並希望同屬於目標染色體的像素向量離該平均向量越近越好，而屬於背景的像素向量(像素標籤為 0)離平均向量越遠越好。

$$L_+ = \frac{1}{N_f} \sum_{i=1}^{N_f} \left[\left\| \mu_f - x_i \right\|_2 - \delta_v \right]_+ \quad (2.5)$$

$$L_- = \frac{1}{N_b} \sum_{i=1}^{N_b} \left[\left\| \mu_f - x_i \right\|_2 - 3\delta_v \right]_+ \quad (2.6)$$

$$Variance\ Loss = L_+ + \frac{1}{L_-} \quad (2.7)$$

本論文中使用的變異數損失(Variance Loss)如(2.5)-(2.7)所示，其中 L_+ 為目標染色體像素貢獻的損失、 L_- 為背景像素貢獻的損失、 N_f 為屬於目標染色體像素的數量、 N_b 為屬於背景像素的數量、 μ_f 為目標染色體在高維空間的平均向量、 x_i 為像素在高維空間的向量。 δ_v 為一可設定之閾值，用來控制類別平均向量與像素向量如果在閾值 δ_v 內，該像素貢獻的損失為 0。

2.3 資料處理

首先本研究所使用的影像會經過物件偵測模型，我們使用的物件偵測模型為文獻[9]所提出，取得染色體物件對應的物件框及類別，透過物件框的座標可以將染色體物件從原圖中取出。取出染色體物件後，為了處理染色體物件影像解析度過小的問題，會找出在該染色體原圖中最長物件框的邊長，並將所有屬於該染色體原圖的染色體物件以填補像素值 255 的方式讓所有影像解析度一致。如此可以避免染色體解析度過小導致將圖片輸入分割模型時，較深層的特徵圖解析度小於卷積核所產生的錯誤。

透過物件偵測、染色體物件擷取、補值，將會得到兩個資料集，分別是屬於榮總醫院的染色體物件及屬於長庚醫院的染色體物件。再來使用 Cycle-GAN 及兩個不同醫院資料集進行模型訓練，最終我們會得到兩個不同方向的風格轉換生成器，這兩個生成器可用來做風格轉換。例如將長庚染色體物件輸入至長庚到榮總風格轉換生成器中，可以保留長庚染色體物件的身分訊息，但將其風格轉換成榮總染色體風格，反之亦然。資料處理流程圖如圖 2.6。




圖 2.6 資料處理流程圖

2.4 基於領域適應染色體分割演算法

在本節，我們使用經過 2.3 節資料處理後得到的 4 種資料集，分別是源域圖片、目標域風格圖片、目標域圖片、源域風格圖片。除了將其兩兩配對並分別搭配兩種不同的領域適應方法進行訓練外，我們也將這兩種不同的領域適應方法整合成一個兩階段訓練的領域適應方式，圖 2.7 為本論文提出之整個系統訓練流程圖。




圖 2.7 本論文提出之領域適應方法流程圖

2.4.1 基於師生模型下的領域適應方法

自訓練(self-training)的概念源自於半監督式學習，其核心思想為找到某種方式對未標註的資料進行標註產生偽標籤(pseudo-label)以擴增資料集。但通常生成的偽標籤不一定完全正確，所以如何篩選品質好的偽標籤是一個決定模型表現優劣的關鍵。從文獻我們使用了典型的師生模型架構，教師模型負責生成偽標籤;學生模型根據偽標籤進行學習。在文獻[14]中，作者觀察到使用源域資料訓練的模

型來預測源域圖片，其熵圖(entropy map)看起來像是邊緣偵測的結果，只有在物件邊緣的地方會有較高的熵;而當預測在目標域圖片，其熵圖在物件邊緣以外也會有許多雜亂、具有高熵的區域，如圖 2.8 所示。所以我們嘗試將熵圖與偽標籤做連結，根據教師模型輸出機率計算熵(entropy)，將其作為每個像素貢獻的損失權重，藉此希望降低品質差的偽標籤對模型的影響，以下是方法的詳細介紹。




圖 2.8 ADVENT[14] 中未使用領域適應對源域及目標域圖片分割結果

透過 Cycle GAN 的風格轉換器，我們可以將目標域(target domain)的圖片輸入到風格轉換器來得到對應的源域(source domain)風格圖片。接著將教師模型跟學生模型載入在源域訓練好的模型權重，並將源域風格圖片輸入到教師模型來得到偽標籤(pseudo label)，並將目標域圖片輸入到學生模型得到輸出。此外，我們利用教師模型輸出的類別機率，計算每個像素機率分布的熵(entropy)，熵的計算公式如(2.8)所示，其中 p 為教師模型輸出機率分布， i 為機率分布中的索引。如果該像素機率分布所計算的熵越高，代表該像素的類別不確定性越高，其生成的偽標籤(pseudo-label)可靠性越低，所以我們希望可靠性低的偽標籤貢獻的損失越低越好。透過計算每個像素的熵並將其正規化(Normalization)至 0 跟 1 之間，並使用 1 減掉正規化後的熵得到每個偽標籤計算損失時對應的權重。最後利用偽標籤權重、偽標籤與學生模型輸出代入損失函數計算損失。反傳遞的過程中，梯度只用來更

新學生模型，教師模型的參數更新透過 Exponential Moving Average (EMA)更新，圖 2.9 為整體架構圖。

$$Entropy = -\sum_i p_i \log_2(p_i) \quad (2.8)$$




圖 2.9 基於師生模型下的領域適應方法

2.4.2 基於風格校正下的領域適應方法

領域適應的研究方向除了使用自訓練(self-training)的方式得到偽標籤以外，另外還有對抗式訓練(adversarial training)。對抗式訓練主要引入了鑑別器(Discriminator)，負責鑑別編碼器輸出的特徵屬於源域或目標域。而編碼器則要輸出讓鑑別器混淆的特徵使鑑別器分類錯誤，這種對抗式的訓練方式使得編碼器輸出的特徵會具有域不變性(domain invariance)，最終的目標為使編碼器將源域及目標域資料在特徵空間的分布是一致的，進而達到領域適應的目的。但對抗式訓練過程常因鑑別器或編碼器中某個模型表現過強導致模式崩壞，使得訓練過程不穩

定。所以在本節，我們不使用對抗式學習，而是採用校正源域及目標域之間特徵統計量的方式進行領域適應。我們使用了 AdaIN[11] 中提出的自適應實例歸一化 (Adaptive Instance Normalization) 來使源域特徵統計量校正成目標域特徵的統計量，其公式如(2.8)。

$$AdaIN(x, y) = \sigma(y) \left(\frac{x - \mu(x)}{\sigma(x)} \right) + \mu(y) \quad (2.9)$$

其中 x 為輸入圖片特徵、 y 為風格圖片特徵、 $\mu(\cdot)$ 為取特徵平均， $\sigma(\cdot)$ 為取特徵標準差。從(2.8)可發現 AdaIN 進行的運算是將輸入圖片特徵的分布轉換成風格圖片特徵分布。而在我們的方法中 x 為源域圖片特徵、 y 為目標域圖片特徵，所以我們在方法中加入自適應實例歸一化的目的在於將源域圖片的特徵統計量轉變為目標域圖片的特徵統計量，再送入解碼器對應的層數中，以下是方法的詳細介紹。

透過 Cycle-GAN 的風格轉換器，我們可以得到與源域(source domain)的資料成對的目標域(target domain)風格圖片。接著我們可以透過將成對的圖片送入與 U-net 相似的編碼器-解碼器架構將每個像素投影到特徵空間，並透過兩個分類器的結果來得到最終的像素分割結果。

本方法的損失函數分為三個部分，第一部份可以利用源域的資料及其像素標記計算交叉熵(cross entropy)作為監督式損失函數。第二部份透過源域圖片及成對的目標域風格圖片，並計算兩者經過編碼器每一層輸出的特徵圖平均值及標準差。將源域特徵圖的平均值及標準差校正為符合風格圖片的分布，並與解碼器對應的特徵圖計算均方誤差(Mean Squared Error)，而這個損失的目標是希望編碼器中每一層特徵圖的分布統計量也需要跟目標域風格圖片類似。第三部分損失函數可透過源域的資料及其像素標記來計算，首先將染色體輸入到模型中，透過另一個分類器可將原本每個一維像素映射到高維的特徵空間。再來使用像素標記當作遮罩，計算目標染色體在高維空間的平均向量。有了目標染色體像素的平均向量後，計算目標染色體像素與該平均向量的變異數(Variance)以及背景像素與平均向量的變異數。最後將目標染色體與平均向量的變異數及背景像素與平均向量的變異數倒數相加，當作第三部分的損失函數。最後將三個損失函數相加後反傳遞更新解碼

器的權重。圖 2.10 為整體架構圖，上半部為訓練階段流程圖，下半部為測試階段流程圖。當模型在訓練階段，需要同時輸入源域的圖片及對應的目標域風格圖片並透過將源域圖片特徵的統計量(平均值、標準差)對齊至合成目標域風格圖片特徵的統計量再輸入到解碼器中計算機率;但當模型在推論時，只需要輸入目標域圖片即能進行推論得到分割結果。




圖 2.10 基於風格校正下的領域適應方法架構圖

2.4.3 結合風格校正與師生模型的領域適應方法

我們嘗試將 2.4.1、2.4.2 節的領域適應方法進行結合，整個訓練過程分成兩個階段。第一階段中，我們對師生模型中的教師模型進行訓練，並使用 Asymmetric Loss 作為損失函數，源域圖片及對應之目標域風格圖片作為輸入，訓練過程中編碼器參數是固定的。訓練架構如圖 2.11 所示。




圖 2.11 結合風格校正與師生模型領域適應方法第一階段訓練示意圖

第二階段中，我們將第一階段訓練的模型作為教師模型，學生模型則是 U-net，並以 Cross Entropy 作為損失函數，並同時以教師模型輸出偽標籤的熵計算偽標籤權重。目標域圖片及對應之源域風格圖片作為教師模型輸入；同時目標域圖片也輸入至學生模型中。訓練過程中我們將教師模型及學生模型中的編碼器參數固定，最後利用偽標籤權重、偽標籤與學生模型輸出代入損失函數計算損失。反傳遞的過程中，梯度只用來更新學生模型，教師模型的參數更新透過 Exponential Moving Average (EMA) 更新。訓練架構如圖 2.12 所示。




圖 2.12 結合風格校正與師生模型領域適應方法第二階段訓練示意圖

2.5 性能評估指標

本論文主要使用 Mean Intersection over Union (MIoU)及 Dice coefficient 來評估主要模型的性能，而前開兩種評估指標皆可使用交並比進行計算，首先介紹交並比(Intersection over Union)。交並比的計算是透過計算兩個集合的交集並除以兩個集合的聯集所得到的，數值介於 0 至 1 之間。數值越高代表兩個集合的重疊度越高，圖 2.13 為交並比示意圖。

而在語意分割任務中，交並比計算所使用的兩個集合分別是模型預測類別跟像素標記類別去計算，而 MIoU 則是透過計算每一個類別的交並比再取平均值；Dice coefficient 則可以透過計算正樣本的交並比再透過公式進行轉換。MIoU 及 Dice coefficient 皆可透過混淆矩陣(Confusion Matrix)來計算，混淆矩陣可將像素的類別根據模型預測結果跟像素標記解答(Ground Truth)分成 4 種類別，分別是真陽性(True Positive)、假陽性(False Positive)、真陰性(True Negative)、假陰性(False Negative)，表 2.2 為混淆矩陣分類定義。

以下為像素被分類為混淆矩陣 4 個類別的定義。

- TP(真陽性): 像素被模型預測為染色體，且像素標記解答也為染色體
- FP(假陽性): 像素被模型預測為染色體，但像素標記解答為背景
- TN(真陰性): 像素被模型預測為背景，且像素標記解答也為背景
- FN(假陰性): 像素被模型預測為背景，但像素標記解答為染色體

$$MIoU = \frac{1}{k+1} \sum_{i=0}^k \frac{p_{ii}}{\sum_{j=0}^k p_{ij} + \sum_{j=0}^k p_{ji} - p_{ii}} \quad (2.10)$$


其中 p_{ij} 為混淆矩陣中第 i 列第 j 行的元素，根據(2.11)，可以將符號置換成混淆矩陣的元素，如(2.10)所示。

$$MIoU = \frac{1}{2} \left(\frac{TP}{TP+FP+FN} + \frac{TN}{TN+FN+FP} \right) \quad (2.11)$$

而 Dice coefficient 可藉由計算正樣本的交並比後再經由公式計算，如(2.12)所示。

$$Dice\ coefficient = \frac{2 \times IoU}{IoU + 1} \quad (2.12)$$

Area of Overlap



Area of Union




圖 2.13 交並比示意圖

表 2.2 混淆矩陣分類定義

		True condition	
		Positive	Negative
Predicted condition	Positive	TP	FP
	Negative	FN	TN

第三章 實驗結果

本章節首先將呈現使用 Cycle-GAN 進行風格轉換的結果，並且評估 2.4 節中提出的 3 種領域適應方法與其他領域適應方法在我們染色體資料庫的效能。評估方式將使用測試集的像素標記作為標準答案並使用 2.5 節的評估指標進行計算。

3.1 訓練超參數設定與實驗設置

本論文在 2.4 節所提出的兩個領域適應染色體分割方法在訓練時的超參數配置細節如表 3.1 所示。我們採用迭代的優化方式 Adaptive Moment Estimation(Adam)，模型訓練週期設定為 50。由於訓練集資料是先透過物件偵測模型得到染色體物件框的位置再將其切割所得，所以訓練集中單條染色體圖片大小非常多元。為了確保染色體物件不會因為 Resize 函式導致有扭曲的狀況產生，所以批次大小設定為 1，學習率為變動值，初始學習率為 0.02。學習率隨著訓練次數逐漸減小，學習率下降方式採取的是餘弦下降，也就是學習率下降過程呈現一個餘弦函數。這可以幫助模型參數在訓練初期快速接近局部最小值，並在訓練後期細化搜索使模型參數靠近局部最小值。在模型權重選擇部分，我們最終保留損失函數值最低的週期權重及最後一個週期權重，並使用兩個權重分別測試在測試集上並選擇 MIoU 最高的權重。

另外在我們的實驗方法中，損失函數除了 Cross Entropy 以外，我們也使用了 Asymmetric Loss[12]。而在 Asymmetric Loss 的設定中，我們需要設定 r_+ 、 r_- 、 m 這三個參數(參照 2.2.3.2 節)，有關 Asymmetric Loss 的參數設定如表 3.2 所示。在 Variance loss 中，我們需要設定 δ_v 這個參數(參照 2.2.3.4 節)，我們的實驗將其設定為 1。

表 3.1 訓練超參數設定

<i>Hyperparameter</i>	<i>Value</i>
Epoch	50
Batch size	1
Optimizer	Adam
Learning rate	0.02
Learning Rate Decay	Cosine annealing

表 3.2 Asymmetric Loss 參數設定

<i>Hyperparameter</i>	<i>Value</i>
r+	0
r-	2
m	0.1

國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

3.2 Cycle-GAN 風格轉換結果呈現

我們使用了 6400 張榮總及 6400 張長庚染色體訓練二元分類器 Resnet-152 [15] 辨別輸入圖像屬於長庚還是榮總的染色體，並用 1600 張榮總及 1600 張長庚染色體進行驗證，保留最高準確率的權重。再將經過 Cycle-GAN 的生成器合成的假圖片輸入至前述訓練完成的二元分類器中，並評估其準確率確保生成器生成圖片與真實圖片是具有高相似度的，表 3.3 為合成圖片經過二元分類器分類之準確度。

表 3.3 合成圖片經二元分類器分類之準確度

Dataset	Accuracy(%)
True Source (1600)	100
True Target (1600)	100
Fake Source(8000)	96.60
Fake Target(8000)	99.25

除了使用二元分類器來幫助判定生成圖片與真實圖片是否具有高相似度外，我們使用其他評估方式來評估圖片風格轉換的品質。首先使用預訓練在 ImageNet 上的深度學習模型並在我們自己的資料庫上進行模型參數微調。再來選定某一層網路輸出之特徵圖，並使用該特徵圖計算格拉姆矩陣(Gram Matrix)，並取格拉姆矩陣對角線上的元素作為該影像的特徵。除了取格拉姆矩陣的對角線作為特徵以外，也可以透過全局最大池化(Global Maxpooling)得到特徵，最後再經由 t-SNE 降至 2 維來觀察各類別影像在特徵維度上的散佈圖。而在我們的評估流程中，首先使用了我們訓練後的二元分類器 Resnet-152，並選擇了 Resnet-152 架構中的 4 個階段(stage)中的最後一層卷積層輸出的特徵圖(分別是第 10、34、142、151 卷積層)，並取其格拉姆矩陣對角線元素或是進行全局最大池化(Global Max Pooling)得到特徵向量。再來我們更進一步針對這些特徵向量進行特徵挑選，透過 Cycle-GAN 我們可以得到成對但不同風格的資料，我們統計這些成對資料間特徵向量之間的差，並選定特徵差前 k 大的特徵，在我們的實驗中，k 設定為 128。最後透過 t-SNE 降至 2 維並做散佈圖，t-SNE[16] (t-distributed Stochastic Neighbor Embedding) 是一種降維和數據可視化技術，適用於高維數據的低維(二維或三維)

可視化，可以幫助使用者理解高維空間數據中的結構及模式。圖 3.1、圖 3.2 分別為將各階段最後一層卷積層輸出之特徵圖取格拉姆矩陣對角元素及全局最大池化後再進行 t-SNE 視覺化的圖。




圖 3.1 Resnet-152 於 Stage 1 (a)、Stage 2 (b)、Stage 3 (c)、Stage 4 (d)特徵圖

取格拉姆矩陣對角元素後 t-SNE 圖




圖 3.2 Resnet-152 於 Stage 1 (a)、Stage 2 (b)、Stage 3 (c)、Stage 4 (d)特徵圖

取全局最大池化後 t-SNE 圖

從圖 3.1、圖 3.2 可以觀察到真實目標域圖片(長庚染色體)與合成目標域風格圖片(長庚風格染色體)在低階特徵(Stage 1、Stage 2)上其分布非常接近;而在比較抽象的高階特徵上其 4 個資料分布已無明顯分界。在低階特徵中雖然真實源域圖片(榮總染色體)與合成源域風格圖片(榮總風格染色體)分布仍有明顯分界，但還是能夠將染色體圖片分成目標域及源域兩個分布。

透過表 3.3、圖 3.1 及圖 3.2 的結果，我們可以確定合成的圖像大部分皆成功的進行風格轉換。圖 3.3 為原始染色體圖片及使用 Cycle-GAN 風格轉換後圖片，無論是將圖片從源域轉換成目標域亦或是把圖片從目標域轉換成源域，在視覺上風格皆非常接近真實圖片所屬的風格。




圖 3.3 原始圖片及 Cycle-GAN 風格轉換圖片

3.3 領域適應技術對語意分割模型效能評估

在本節我們將評估提出的領域適應方法，並以使用目標域圖片進行模型參數微調(finetune)作為模型表現上限;將只使用源域圖片訓練的模型表現作為表現下限。分割模型皆使用 U-net，而為了評估使用目標域圖片進行微調後的模型表現，我們將已有的 1523 張目標域圖片及其像素標籤切分為 1066 張及 457 張染色體物件。使用 1066 張染色體物件對模型參數微調，並使用 457 張染色體物件進行評估，評估結果如表 3.4 所示。

表 3.4 目標域 457 張染色體物件評估結果

Domain Adaptation Method	MIoU(%)	DICE(%)
Only train on Source domain (baseline)	88.88 (0%)	88.22 (0%)
Cycle GAN (Source to Target)	91.41 (41.48%)	91.19 (43.68%)
Cycle GAN (Target to Source)	88.51 (-6.07%)	87.86 (-5.29%)
Cycle GAN + Teacher-Student (ours)	92.66 (61.97%)	92.18 (58.24%)
Cycle GAN + AdaIN (ours)	93.15 (70%)	93.11 (71.91%)
Cycle GAN + Teacher-Student + AdaIN(ours)	93.22 (71.15%)	93.17 (72.79%)
Finetune on Target Domain	94.98 (100%)	95.02 (100%)

從表 3.4 可觀察到，當分割模型只訓練在源域的資料上時，使用目標域資料驗證，其 MIoU 只有 88.88 %，Dice 係數為 88.22 %。而如果加上目標域資料 1066 張進行模型參數微調可得到 MIoU 為 94.98 %，Dice 係數為 95.02 %，而這些數值做為評估領域適應策略的上下限。一個良好的領域適應策略應該在不使用目標域的標記資料下，使模型表現比前述評估指標下限還要高。我們在這節分別使用 5

種不同的領域適應策略進行比較，其中三個分別為我們在 2.4 節提出的兩種方法及其組合，以下將詳細說明。

- (1) **Cycle GAN (Source to Target):** 透過 Cycle-GAN 中的源域轉目標域風格生成器，將源域圖片轉為目標域風格圖片，再利用目標域風格圖片跟源域標記來微調模型參數，其 MIoU 為 91.41 %，Dice 係數為 91.19 %。
- (2) **Cycle GAN (Target to Source):** 透過 Cycle-GAN 中的目標域轉源域風格生成器將目標域圖片轉為源域風格圖片，並直接使用在源域訓練好的分割模型進行分割，其 MIoU 為 88.51 %，Dice 係數為 87.86 %。
- (3) **Cycle GAN + Teacher-Student (ours):** 透過 Cycle-GAN 中的目標域轉源域風格生成器將目標域圖片轉為源域風格圖片，使用在源域訓練好的模型權重初始化教師模型及學生模型。並將源域風格圖片輸入至教師模型；目標域圖片輸入至學生模型。並計算教師模型輸出機率的熵作為權重調整每個像素貢獻的損失大小，最後透過倒傳遞訓練學生模型，教師模型則透過 Exponential Moving Average (EMA) 進行更新，其 MIoU 為 92.66 %，Dice 係數為 92.18 %。
- (4) **Cycle GAN + AdaIN (ours):** 透過 Cycle GAN 中的源域轉目標域風格生成器，將源域圖片轉為目標域風格圖片。並將源域圖片跟對應的目標域風格圖片一同送入分割模型中，並透過校正源域圖片各個尺度特徵圖的統計量至目標域中來達到良好的分割效果，其 MIoU 為 93.15 %，Dice 係數為 93.11 %。
- (5) **Cycle GAN + Teacher-Student + AdaIN(ours):** 我們也嘗試將師生模型跟自適應實例歸一化結合，在教師模型中加入自適應實例歸一化，期望藉此增加教師模型產出的偽標籤品質。同時計算教師模型輸出的機率並求得每個像素的熵，再計算損失權重來減少品質較差的偽標籤貢獻的損失。其 MIoU 為 93.22，Dice 係數為 93.17 %。

此外為了確認評估結果的可靠性，除了使用目標域圖片微調模型參數的方式外，我們也使用目標域已有像素標籤的 1523 張圖片進行驗證，評估結果如表 3.5 所示。從表 3.4 及表 3.5 可發現使用我們提出的兩種領域適應方式及其組合，其模型效能皆優於未使用領域適應的模型效能，這證實了我們的領域適應方法有效性。

此外，我們也觀察了各種策略下訓練之模型在驗證集數據量增加時的效能變化。僅使用 Cycle-GAN 的策略，無論是使用源域轉目標域或目標域轉源域的風格轉換器，模型效能會隨著驗證集數據量的增加，表現出下降趨勢。使用 Cycle-GAN 搭配自適應實例歸一化，模型效能也會隨著驗證集數據量的增加而出現下降趨勢。但只要有結合師生模型的策略，模型效能反而有所提升，這可能說明了師生模型會使模型表現更穩定。

這些結果表明，僅單獨使用 Cycle-GAN 可能不足以應對驗證集數據量增加所帶來的挑戰，而結合自適應實例歸一化或師生模型等技術，能夠提高模型的穩健性和效能。在更大數據量的驗證集上，這些策略能有效地保持甚至提升模型的表現。

表 3.5 目標域 1523 張染色體物件評估結果

Domain Adaptation Method	MIoU(%)	DICE(%)
Only train on Source Domain (baseline)	88.83	88.18
Cycle GAN (Source to Target)	90.50	90.18
Cycle GAN (Target to Source)	88.20	87.51
Cycle GAN + Teacher-Student (ours)	92.91	92.22
Cycle GAN + AdaIN (ours)	93.14	93.05
Cycle GAN + Teacher-Student + AdaIN(ours)	93.22	93.16

圖 3.4 及圖 3.5 分別代表了使用師生架構或自適應實例歸一化模型在目標域圖片的分割結果;圖 3.6 為結合兩種領域適應方法的模型在目標域圖片的分割結果。可以觀察到在未重疊及少量重疊的染色體影像上，模型能完整地將染色體物件分割出來，但在高度重疊的染色體上仍然有分割錯誤的發生。另外我們也測試了人工標註及模型推論需要花費的時間，人工標註完整的一張染色體原圖大約需要 2 至 3 小時，但使用模型推論只需要 24 秒，可以有效減少標註時間。




圖 3.4 (a)目標域染色體圖、(b)染色體物件、(c)Teacher-Student 領域適應模型分割結果




圖 3.5 (a)目標域染色體圖、(b)染色體物件、(c)AdaIN 領域適應模型分割結果




圖 3.6 (a)目標域染色體圖、(b)染色體物件、(c)AdaIN 結合 Teacher-Student 領域適應模型分割結果

第四章 討論

4.1 參數設定對師生模型效能評估

本節我們將討論師生模型架構下不同的參數設定及損失函數的選擇對效能的影響。例如教師模型參數更新方式 Exponential Moving Average (EMA) 的平滑更新參數設定。參數更新公式如式(4-1)，其中 θ 代表教師模型參數、 α 為平滑更新參數、 δ 為學生模型參數、 t 為參數更新輪數。根據文獻[17]實驗結果，在平滑更新參數大於 0.99 的時候，其驗證集的錯誤率較低，且較高的平滑更新參數可以保持模型在訓練過程中比較穩定。所以我們將平滑更新參數設定為 0.9999、0.9996、0.999、0.99 進行測試，損失函數選用 Cross Entropy 或 Asymmetric Loss，並且考慮是否使用教師模型輸出機率的熵計算損失權重，最後觀察這些參數設定對模型效能影響。

$$\theta_{t+1} = (1 - \alpha)\delta_t + \alpha\theta_t \quad (4.1)$$

從圖 4.1 及圖 4.2 可觀察到當平滑更新參數 α 為 0.99 時，可以得到最佳的模型表現。另外我們也發現使用教師模型輸出機率的熵作為權重調整每個像素貢獻的損失大小，可以減少可信度低的偽標籤貢獻的損失，進而使模型效能增加。而在損失函數的選擇，由於我們對 Asymmetric Loss 的設定，不影響正樣本像素對整體損失函數的貢獻；而在簡單負樣本像素貢獻的損失會消失，並且負樣本損失主要會由困難負樣本像素貢獻。不過在實驗結果中發現使用 Cross Entropy 會略優於使用 Asymmetric Loss。最終在平滑更新參數 α 在 0.99 下，使用 Cross Entropy 作為損失函數並使用教師模型輸出機率的熵作為權重調整每個像素貢獻的損失會有最好的模型效能。



圖 4.1 不同參數設定下對教師模型 MIoU 表現




圖 4.2 不同參數設定下對教師模型 Dice coefficient 表現

4.2 複合損失函數對分割模型效能評估

在本節我們將討論 U-net 結合自適應實例歸一化模型在不同損失函數組合下效能的影響。我們選擇了 Cross Entropy 以及 Asymmetric Loss 做為主要的損失函數，並分別搭配了 Style Loss 及 Variance Loss 來觀察對模型效能的影響。其中 Style Loss(見 2.2.3.3 節)是透過每層編碼器輸出經過 AdaIN 校正後的特徵圖平均值及標準差與相對應的解碼器每層特徵圖的平均值及標準差計算均方誤差(Mean Square Error)所得。而 Variance loss (見 2.2.3.4 節)則是將解碼器輸出的特徵圖透過 1x1 卷積將每個像素投影到高維空間中，透過像素標記，得到屬於前景的像素的平均向量後，分別計算圖像中每一個像素跟平均向量的距離，並希望屬於前景像素的變異數越小越好，而背景像素的變異數越大越好。


表 4.1 不同損失函數組合對模型效能評估

Loss function	MIoU(%)	DICE(%)
Baseline	88.83	88.18
Cross Entropy	92.35	92.18
Cross Entropy + Style Loss	91.59	91.33
Cross Entropy + Variance Loss	92.26	92.09
Cross Entropy + Style Loss + Variance Loss	91.94	91.71
Asymmetric Loss	92.48	92.34
Asymmetric Loss + Style Loss	91.01	90.69
Asymmetric Loss + Variance Loss	93.14	93.05
Asymmetric Loss + Style Loss + Variance Loss	92.81	92.72


從表 4.1 可以發現選用 Asymmetric Loss 搭配 Variance Loss 的組合訓練模型會使分割效能最好。而無論哪種損失函數組合，當主損失函數為 Asymmetric Loss 時，其模型表現幾乎相較於主損失函數為 Cross Entropy 還要好，這是由於 Asymmetric Loss 相較於 Cross Entropy，考慮到了正樣本及負樣本中樣本難易程度對損失貢獻的程度，較困難的樣本其貢獻的損失較大;較容易的樣本其貢獻的損失較小。且 Asymmetric Loss 又透過設定閾值的方式來去除了簡單負樣本對損失的貢獻，這同

時也有利於解決樣本不平衡的問題，這種情形非常適用於我們的染色體分割任務。因為在資料處理步驟為了保持每對染色體的相對大小保持不變，對於較小的染色體物件會透過補背景值的方式將屬於同一張染色體圖的染色體物件變為同樣圖片大小，而這樣的處理方式也會導致分割任務的背景像素大量增加，所以背景像素會遠多於前景像素，所以 Asymmetric Loss 會是一個恰當的損失函數選擇。此外我們也可以觀察到 Style Loss 對於模型表現有著負面的影響，這個實驗結果意味著在語意分割任務中，限制解碼器每層輸出的特徵圖平均值及標準差需要與校正過特徵圖的平均值及標準差盡量接近是沒有幫助的。

最後我們觀察到 Variance Loss 的加入對模型的表現是有幫助的，透過計算前景像素的平均向量，並透過降低 Variance Loss 使前景像素在高維空間中聚集；背景像素遠離前景像素的質心，能減少一些染色體重疊的問題。圖 4.3 中的(a)圖為加入了 Variance Loss 進行訓練後的 pixel embedding t-SNE 圖；(b)圖為未加入 Variance Loss 進行訓練後的 pixel embedding t-SNE 圖，從圖中可以觀察到加入了 Variance Loss 訓練後的前景像素其在高維特徵空間會聚集在一起，且背景像素有往前景像素的質心外擴散的情況發生。對比未加入 Variance Loss 訓練的 t-SNE 圖，可以發現前景像素及背景像素在高維特徵空間是混合在一起的情況，所以可以發現加入 Variance Loss 後是有利於聚合前景像素的。



(a) Train with variance loss



(b) Train w/o variance loss

圖 4.3 目標染色體及背景像素 pixel embedding t-SNE 圖

4.3 文獻方法比較

表 4.2 為使用我們的方法與其他領域適應方法訓練模型後模型效能的比較，這些領域適應方法在原始論文中皆使用於合成街景適應真實街景的語意分割任務。在本節首先會先分別介紹三個領域適應方法，再來分析這三個領域適應方法不適用於我們的染色體資料庫原因。

表 4.2 方法與文獻比較

領域適應方法	分割模型	MIoU(%)
Only train on source domain (baseline)	U-net	88.83
ADVENT [14]	Deeplab v2	31.53
MCD [18]	FCN	47.48
DAFormer [19]	MIT	90.67
Cycle GAN + Teacher-Student (ours)	U-net	92.91
Cycle GAN + AdaIN (ours)	U-net	93.14
Cycle GAN + Teacher-Student + AdaIN (ours)	U-net	93.22

- (1) ADVENT [14]: 提出兩種互補的方式達到領域適應的效果，分別是 entropy loss 以及對抗式學習的架構。作者觀察到當模型使用在源域資料時，只有在物體邊緣會有較大的熵；但當模型使用在目標域資料時除了物體邊緣以外也會出現較大的熵，所以作者提出 entropy loss 目的是限制模型的輸出機率在計算熵時要盡可能的最小化。對抗式學習則是加入鑑別器進行訓練，鑑別器目的是盡可能的區分源域及目標域的圖片，而分割模型輸出的特徵圖則要盡量使鑑別器分類錯誤。
- (2) MCD [18]: 使用兩個不同初始權重的分類器，並在源域訓練得到兩個不同參數但在源域資料都表現優異的模型，將資料輸入模型其中包含特徵萃取器及兩個不同的分類器，藉由最大化兩個分類器輸出的機率差異找出遠離源域特徵的目標域樣本，再藉由最小化兩個分類器輸出的機率差異來更新特徵萃取器使得特徵萃取器學習到的特徵會接近目標域特徵，藉此達到領域適應的效果。

(3) DAFormer [19]: 使用了 Teacher-Student 架構及資料擴增方法 ClassMix[20]

來合成源域與目標域的混合圖片，將源域及混合圖片輸入至學生網路，目標域圖片輸入至教師網路進行訓練。並結合了三種訓練策略來改善領域適應語意分割的性能，分別是稀有類別採樣、ImageNet 特徵距離、學習率預熱(warm up)。稀有類別採樣針對出現類別數較少的圖片進行過採樣，使訓練資料類別數平衡; ImageNet 特徵距離使用在 ImageNet 上預訓練的特徵對模型進行正則化，使模型訓練時不會過於偏向合成數據的特徵;學習率預熱則是能穩定模型訓練過程。

從表 4.2 可以看到在 ADVENT、MCD 皆使用對抗式學習架構訓練出來的模型表現效能較低，這可能是由於染色體資料庫與街景資料庫的差異所導致的情況。像是 ADVENT 中所提出的 entropy loss 會使模型輸出機率有著最小化的熵，而在我們的染色體資料庫中，染色體物件會含有許多條顯帶(band)，而這些顯帶顏色不一是因為不同染色質區域對染色劑的親和力不同所導致。而這也導致了最小化熵這個目標不適用於我們的資料集中。此外，使用對抗式學習進行訓練，需要依賴鑑別器(Discriminator)使得源域與目標域圖片在特徵空間中的距離逐步縮小，而這種訓練方式，會由於訓練過程中，鑑別器或分割模型的特徵萃取器其中一方的效能遠勝於另一方而導致訓練不穩定或失敗。

而 DAFormer 使用的資料擴增方式及訓練策略並不適合我們的染色體資料庫。在 DAFormer 中，使用了 Feature Distance (FD)這一策略，透過損失函數限制模型透過特徵萃取器所得到的特徵不能與 ImageNet 的特徵有太大的差異。但在我們的染色體資料庫中，染色體影像與 ImageNet 影像存在明顯的差異性，我們推測該策略在我們的資料集上會降低模型的整體準確率。另外不適合使用 ClassMix 進行資料擴增是由於我們的染色體資料為經過物件偵測模型所得到之物件框所裁切圖片，標記過程只針對主染色體進行標記。如果採用 ClassMix 的方法進行資料擴增，產生的圖片及像素標記並不適合訓練。當 ClassMix 進行資料增廣時，會隨機保留源域圖片上一半類別所屬的像素，其餘像素使用目標域圖片的像素進行填補。而在我們的資料集中分別有染色體及背景兩種類別，我們發現當資料增廣時保留到源域圖片的背景像素，生成的圖片不符合真實情況，如圖 4.4 所示，使用這些生成圖片訓練可能會降低模型的準確率。

表 4.3 為 DAFormer 的消融性實驗結果，我們按照作者提供的訓練參數及策略並使用我們的染色體資料庫進行訓練，在測試集中得到的評估指標 MIoU 為 90.67 %。透過將 Feature Distance 從 DAFormer 移除，得到 MIoU 為 90.91 %，提升了 0.24%。我們也修改了 ClassMix 中選取保留類別的方式，從隨機保留類別固定為保留源域圖片中染色體類別的像素，防止產生圖 4.4 (c)這種不合理的圖片合成，得到 MIoU 為 91.1 %，提升了 0.43%。最終我們將前述兩種修改結合，所得到 MIoU 為 91.83 %，提升了 1.16%。從表 4.3 的結果顯示了在 DAFormer 的原本訓練設定跟策略，並不全然適用在我們的染色體資料庫，需要經過適當的修改，提高模型的效能。但效能仍然低於我們的領域適應方法。




圖 4.4 (a) 源域圖片、(b)目標域圖片、(c) 使用 ClassMix[20] 生成圖片

表 4.3 DAFormer 消融性實驗結果

Method	Feature Distance	Randomly Reserve Class	MIoU(%)
DAFormer	✓	✓	90.67
	✗	✓	90.91
	✓	✗	91.1
	✗	✗	91.83

4.4 應用於語意分割模型的決策可視化

模型決策可視化技術用於幫助使用者理解和解釋複雜機器學習模型，藉由可視化模型決策提高模型決策的透明度和可信度，目前已經有許多模型決策可視化的方法被提出。在本節，我們使用 Gradient-weighted Class Activation Mapping(簡稱 Grad-CAM) [21] 來可視化模型決策，透過反傳遞模型預測為前景的像素機率總和來觀察模型主要關注圖像的哪些區域。我們隨機選擇 10 張染色體物件進行決策可視化，其中包含未重疊及重疊的染色體各 5 張，如圖 4.5、圖 4.6 所示。我們可以觀察到模型關注的區域幾乎都在目標染色體上，唯有一些具有高度重疊的染色體物件的梯度熱圖錯誤。使用 Cycle-GAN + Teacher-Student 訓練的模型其前景的梯度大小幾乎一致；而使用 Cycle-GAN+AdaIN 訓練的模型雖然梯度熱圖也在目標染色體上，不過可以發現其梯度較高的位置集中在顯帶的部分，顯示出模型關注在染色體顯帶的位置。

國立中興大學

NATIONAL CHUNG HSING UNIVERSITY




圖 4.5 未重疊染色體 Grad-CAM 圖




圖 4.6 重疊染色體 Grad-CAM 圖

第五章 結論與未來方向

5.1 結論

在本論文中，我們提出一套基於 Cycle-GAN 與領域適應技術的自動染色體分割系統，可以在缺少目標域標籤的情況下，訓練一個可使用於目標域上的分割模型並應用在跨院驗證程序上，節省了目標域資料標記的人力資源及時間成本，同時使模型在使用目標域資料驗證時不會出現效能降低的情況。我們首先利用源域及目標域資料訓練 Cycle-GAN，並提出了三個領域適應策略。

- (1) Cycle GAN (Target to Source) + Teacher-Student
- (2) Cycle GAN (Source to Target) + AdaIN
- (3) Cycle GAN + AdaIN + Teacher-Student

透過分別使用 Cycle-GAN 中的兩個生成器搭配師生模型架構、自適應實例歸一化及兩種方法的結合，解決不同來源染色體圖片風格及特徵差異導致模型效能降低的情形。將師生模型架構、自適應實例歸一化結合可以得到最好的評估結果 MIoU 93.22%，Dice coefficient 93.16%。即使將師生模型架構、自適應實例歸一化個別使用，其評估指標 MIoU 也達到了 92.91% 及 93.14%，Dice coefficient 92.22% 及 93.05%，皆優於未使用領域適應的模型評估指標 MIoU 88.83% 及 Dice coefficient 88.18。另外也與一些使用於複雜分割任務上的領域適應方法進行比較，我們的方法較適用在染色體物件資料集上。最後我們加入了 Grad-CAM 熱圖將決策視覺化，幫助醫事人員可直觀的理解模型決策。

5.2 未來方向

本論文提出的方法可以在不存取目標域資料標記下得到一個能在目標域良好分割染色體的模型，但仍會有分割錯誤的情形，而造成分割錯誤的情況可能來自於語意分割任務上的本質，由於語意分割跟實例分割的差別在於語意分割不會考慮物體的實例，也就是不區分同一類別的不同實體；實例分割則是會考慮到物體實例，區分同一類別的不同實體。而當染色體原圖使用物件偵測模型得到物件框時，

有些物件框內可能含有多隻完整染色體，這使得語意分割模型可能將多隻染色體分割下來，進而降低我們的模型表現。

提示工程(prompt engineering)藉由使用者給予生成式 AI 一段提示(prompt)藉此誘導模型生成使用者想要的結果，而提示的類型可以是各種不同種類的資料型態，最常見的是文字，藉由給予生成式 AI 一段文字，誘導 AI 生成符合文字敘述的圖像。而在語意分割任務中，已經有類似的模型架構使用此概念，例如 Segment Anything[22]，使用者透過滑鼠點擊想要切割的物件，而這個事件會當作是提示(prompt)輸入到模型當中，而模型也會輸出相對應的分割結果。而這種透過額外給予提示(prompt)的方式，或許可以解決語意分割中無法區分同一類別中不同實例的限制。

在醫療影像分析中，模型穩健性具有極其重要的意義，主要是因為醫療領域對準確性、安全性和可靠性的要求極高，醫療決策對患者的健康影響甚鉅，因此模型可靠性尤為重要。一個穩健的模型能夠保持穩定的表現，減少因為輸入數據的變化而導致的結果波動，從而提高醫療決策的可靠性。近年來，陸續有學者對穩健遷移式學習(robust transfer learning)進行研究，穩健遷移式學習除了提高模型在源域訓練並在目標域應用的能力外，也必須將源域模型的穩健性轉移到目標域模型中，提高目標域模型的泛化能力。其中模型穩健性指的是模型即使面對擾動、具有噪音的輸入資料，也不會影響其效能表現。從文獻[23, 24]中發現，訓練一個具有穩健性的源域模型再進行遷移式學習可以使源域模型的穩健性轉移到目標域模型上。比較常見的提高模型穩健性的方式是生成對抗樣本(Adversarial Samples)，藉由投影梯度下降法(Projected Gradient Descent)[25]來生成對抗樣本，透過限制樣本擾動的程度，並反覆藉由投影梯度下降法找到可最大化損失函數的對抗樣本。最後將對抗樣本及對應之源域標籤加入到訓練過程，進而提高模型的穩健性。

在醫療輔助軟體的推廣上，跨院驗證是一個必要的驗證程序，這種驗證方式涉及多個不同醫療機構或研究中心，以確保研究結果的普遍性和可重複性。在現階段，我們使用兩間不同醫療機構的染色體圖像對模型的分割效能的進行評估，為了驗證我們提出的領域適應策略泛用性，應該多增加不同來源(多個目標域)的染色體資料進行驗證，確保我們的領域適應方法具有泛化性及可重複性，即使在

源域對多個目標域的資料上，仍然可以在不存取目標域標記的情況下提升模型的分割效能。

綜上所述，在未來工作中，我們計劃從三個面向拓展研究，如圖 5.1 所示。本論文針對染色體影像分割中的領域適應問題提出了解決方案，也揭示了許多值得進一步研究的方向，通過持續改進及研究，相信能進一步提升模型的實用性和應用價值，同時也期許此方法能應用於其他醫療影像的領域適應問題，例如不同權重下的磁共振造影(Magnetic Resonance Imaging)。



圖 5.1 未來研究方向示意圖

參考文獻

- [1] Yu-Qian, Z., et al. *Medical images edge detection based on mathematical morphology*. in *2005 IEEE engineering in medicine and biology 27th annual conference*. 2006. IEEE.
- [2] Chen, W., et al., *Automated ventricular systems segmentation in brain CT images by combining low-level segmentation and high-level template matching*. BMC medical informatics and decision making, 2009. **9**(1): p. 1-14.
- [3] Li, S., T. Fevens, and A. Krzyżak. *A SVM-based framework for autonomous volumetric medical image segmentation using hierarchical and coupled level sets*. in *International Congress Series*. 2004. Elsevier.
- [4] Ronneberger, O., P. Fischer, and T. Brox. *U-net: Convolutional networks for biomedical image segmentation*. in *Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18*. 2015. Springer.
- [5] Gadermayr, M., et al., *Generative adversarial networks for facilitating stain-independent supervised and unsupervised segmentation: a study on kidney histology*. IEEE transactions on medical imaging, 2019. **38**(10): p. 2293-2302.
- [6] Chen, C., et al., *Unsupervised bidirectional cross-modality adaptation via deeply synergistic image and feature alignment for medical image segmentation*. IEEE transactions on medical imaging, 2020. **39**(7): p. 2494-2505.
- [7] Yang, J., et al. *Unsupervised domain adaptation via disentangled representations: Application to cross-modality liver segmentation*. in *Medical Image Computing and Computer Assisted Intervention—MICCAI 2019: 22nd International Conference, Shenzhen, China, October 13–17, 2019, Proceedings, Part II 22*. 2019. Springer.
- [8] Perone, C.S., et al., *Unsupervised domain adaptation for medical imaging segmentation with self-ensembling*. NeuroImage, 2019. **194**: p. 1-11.
- [9] 李峻州, 一套基於深度學習的核型圖染色體自動偵測辨識系統, in *自動控制工程學系*. 2022, 逢甲大學: 台中市. p. 43.
- [10] Zhu, J.-Y., et al. *Unpaired image-to-image translation using cycle-consistent adversarial networks*. in *Proceedings of the IEEE international conference on computer vision*. 2017.
- [11] Huang, X. and S. Belongie. *Arbitrary style transfer in real-time with adaptive instance normalization*. in *Proceedings of the IEEE international conference on computer vision*. 2017.

- [12] Ridnik, T., et al. *Asymmetric loss for multi-label classification*. in *Proceedings of the IEEE/CVF international conference on computer vision*. 2021.
- [13] De Brabandere, B., D. Neven, and L. Van Gool, *Semantic instance segmentation with a discriminative loss function*. arXiv preprint arXiv:1708.02551, 2017.
- [14] Vu, T.-H., et al. *Advent: Adversarial entropy minimization for domain adaptation in semantic segmentation*. in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2019.
- [15] He, K., et al. *Deep residual learning for image recognition*. in *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016.
- [16] Van der Maaten, L. and G. Hinton, *Visualizing data using t-SNE*. Journal of machine learning research, 2008. **9**(11).
- [17] Tarvainen, A. and H. Valpola, *Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results*. Advances in neural information processing systems, 2017. **30**.
- [18] Saito, K., et al. *Maximum classifier discrepancy for unsupervised domain adaptation*. in *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018.
- [19] Hoyer, L., D. Dai, and L. Van Gool. *Daformer: Improving network architectures and training strategies for domain-adaptive semantic segmentation*. in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022.
- [20] Olsson, V., et al. *Classmix: Segmentation-based data augmentation for semi-supervised learning*. in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. 2021.
- [21] Selvaraju, R.R., et al. *Grad-cam: Visual explanations from deep networks via gradient-based localization*. in *Proceedings of the IEEE international conference on computer vision*. 2017.
- [22] Kirillov, A., et al. *Segment anything*. in *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2023.
- [23] Agarwal, P., et al. *Unsupervised robust domain adaptation without source data*. in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. 2022.
- [24] Li, L., Y. Zhou, and G. Yang. *Robust source-free domain adaptation for fundus image segmentation*. in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. 2024.
- [25] Madry, A., et al., *Towards deep learning models resistant to adversarial attacks*. arXiv preprint arXiv:1706.06083, 2017.